

Detección de fraude en verificación de identidad

Del análisis de los datos a un sistema que decide aprobar, verificar o rechazar casi en tiempo real

EL PROBLEMA

Fraude de identidad en el onboarding

17.781

intentos de verificación

12.206

cuentas

2

clientes, nov 2023 – ago
2024

17,7 %

de fraude

Dónde actúa el modelo

Documento y selfie



Señales e historial



Modelo de riesgo



Aprobar · verificar ·
rechazar

Subtipos observados: documento falso, suplantación con foto, identidad robada, defraudador conocido, identidad en varias cuentas

RESUMEN

El resultado en una lámina

0,544

PR-AUC en test. El azar da 0,163

43 %

del fraude detenido

1,3 %

de clientes buenos perdidos (0,17 % por rechazo directo)

-24,5 %

de costo frente a no tener modelo



El límite está en los datos, no en el modelo: las señales que más informan en fraude llegaron aleatorizadas.

Supuesto de costos: rechazar a un cliente bueno cuesta 2 veces lo que cuesta un fraude (S6)

SUPUESTOS

Supuestos que condicionan el diseño

Supuesto	Por qué	Consecuencia
S3 · El resultado del proceso no se conoce al decidir	STATUS y DECLINED_REASON son el resultado de la verificación	Fuera del modelo principal (con ellos: 0,61)
S6 · Rechazar a un bueno cuesta 2× un fraude	Se pierde un cliente nuevo: su valor futuro y su costo de adquisición	Fija los umbrales; se acompaña de sensibilidad
S8 · Las etiquetas llegan tarde	Al decidir, el fraude del intento anterior aún no se conoce	Sin fraudes previos como variable; evaluación por cohortes maduras
S10 · El tiempo no es representativo	Meses con 100 % de fraude; clientes sin solaparse	Validación por cuenta; 295 filas fuera

Los datos no eran lo que parecían

Dos esquemas distintos


DISTRUST y Distrust nunca coinciden: cada cliente nombra distinto. **Se unifican.**

Meses con 100 % de fraude

Sesgo de selección: inflaba el PR-AUC de 0,52 a 0,62. **Se excluyen.**

Etiqueta casi por cuenta

Solo 3,7 % de las cuentas mezcla etiquetas. **Partición por cuenta.**



HALLAZGO PRINCIPAL

25 columnas eran ruido sintético

1 · Son internamente imposibles

- Código de país = nombre del país en el 24,5 % (azar: 25 %)
- Más IPs en 5 minutos que en 1 hora en el 45 %
- "Visto por primera vez" después de todas las transacciones
- Latitud de -90 a 90 con solo 4 países

2 · No tienen señal ni combinadas

LightGBM con...	AUC
Las 25 columnas de ruido	0,490
Control negativo: etiqueta al azar	0,489
Control positivo: 3 señales reales	0,762

VPN, dispositivo, velocidad de IPs y geolocalización: las señales más usadas en fraude de identidad, aleatorizadas por la anonimización. **Se excluyen, con evidencia.**

VARIABLES

Cada variable solo mira el pasado

22 variables, 5 grupos

- Señales del proveedor, unificadas
- Historial de la cuenta: fallos, rechazos por riesgo, velocidad
- Identidad compartida entre cuentas
- Historial del documento y del email
- Faltantes como señal

Test de viaje en el tiempo

Calcula las variables con todo el dataset y cortando en 4 fechas: el pasado no puede cambiar.

0,524 → 0,549

Feature engineering: 7 variables nuevas de historial e identidad, medidas con validación cruzada agrupada por cuenta.

MODELADO

Un modelo simple, explicable y calibrado

Experimento	PR-AUC	Lectura
Regresión logística	0,511	Línea base
LightGBM monótono	0,549	Elegido
Sin las 7 variables nuevas	0,524	Aporte del feature engineering
Sin DISTRUST	0,532	No depende de una sola señal
Con fuga (resultado del proceso)	0,613	Ilusorio en producción

Por qué LightGBM: faltantes y categorías nativas, probabilidades calibradas y restricciones monótonas.

Sin SMOTE ni ponderación: distorsionan las probabilidades que usa la decisión.


Hiperparámetros conservadores: árboles de 7 hojas y 100 casos mínimos por hoja.

EVALUACIÓN

Validación y prueba coinciden

Métrica	Validación	Test
PR-AUC	0,549	0,544
ROC-AUC	0,818	0,811
Recall con 5 % FPR	0,394	0,416
Brier	0,102	0,102

IC 95 % del PR-AUC: **0,43–0,64**, remuestreando cuentas. Por cliente: A 0,67 · B 0,50.



Recall con 5 % de falsos positivos: cuánto fraude se detecta molestando solo al 5 % de los clientes buenos

EXPLICABILIDAD

Cada decisión se puede explicar

RECHAZO · SCORE 0,98

Desconfianza del proveedor: 0,95 · **+1,64**


Intentos previos con el mismo email: 14 · **+1,23**

Rechazos previos por señales de fraude: 4 · **+1,19**

Monótono por diseño: más señal de riesgo nunca baja el score.
Verificado por tests.

Exacto: valor base + aportes = score, verificado por tests.

Efecto de cada valor: monótono por diseño



Valores SHAP nativos de LightGBM · solo verificaciones y rechazos llevan motivos · aportes en log-odds

LÓGICA DE DECISIÓN

Decidir por costo, no por un umbral fijo

Aprobar · score menor a 0,28


81,0 % del tráfico · 8,5 % de fraude

Verificar (OTP, selfie, analista)

0,28 a 0,83 · 17,4 % del tráfico · 46 % de fraude

Rechazar · score desde 0,83

1,5 % del tráfico · 91 % de fraude





Para cada proceso se elige la acción de **menor costo esperado**. Con probabilidades calibradas, los umbrales salen de una fórmula: **cambiar los costos no requiere reentrenar**.

Umbrales: donde se cruzan los costos esperados de las acciones

ANÁLISIS DE SENSIBILIDAD

El negocio decide cómo usar el modelo



0,5x · rechaza 6,1 % · detiene 59 % del fraude · pierde 4,5 % de buenos

2x (S6) · rechaza 1,5 % · detiene 43 % · pierde 1,3 %

5x · rechaza 0,8 % · detiene 27 % · pierde 0,4 %

Eje: costo de rechazar a un cliente bueno ÷ costo de un fraude · Umbrales fijados en train, impacto medido en test

SISTEMA EN PRODUCCIÓN

Un sistema que corre en local



Unas 900 líneas: cada una se puede explicar · los tests hallaron 3 errores reales

MONITOREO BÁSICO

Monitoreo en tres niveles

AL INSTANTE

Deriva de datos

PSI de cada variable y del score frente a train. Alerta sobre 0,25.

AL INSTANTE

Deriva de decisiones

% de aprobar, verificar y rechazar frente a lo esperado. Alerta sobre 5 puntos.

CON RETRASO

Desempeño

PR-AUC y negocio, solo con etiquetas maduras y un mínimo de casos.

Prueba: DISTRUST + 0,3

PSI 5,6

Alerta inmediata, aunque las decisiones apenas cambiaron (aprobación de 80,9 % a 76,2 %). **Hay que vigilar las entradas, no solo las salidas.**

Cada predicción queda registrada con sus variables y la versión del modelo · reporte con estado OK o ALERTA

ESCENARIOS

Cuatro escenarios de producción

El fraude sube de repente

Primero, ¿es real? Proveedor caído o etiqueta redefinida. Luego, dónde y si es una red (identidades compartidas). Mitigar bajando umbrales sin reentrenar.

Bien offline, mal en producción

Fuga offline, distinto preprocesamiento, evaluación optimista o señales faltantes. Cada una tiene aquí un test o una alerta.

Demasiados buenos rechazados

Medir (apelaciones, verificaciones superadas), buscar deriva o segmento, subir el costo del rechazo y mover casos a verificación.

Etiquetas con retraso

En capas: deriva al instante, señales tempranas en días y desempeño solo por cohortes maduras. Reentrenar solo con datos maduros.

CIERRE

Limitaciones y cómo se acotan

Limitaciones

- Señales de dispositivo y red aleatorizadas
- Dos clientes; el B con un solo mes
- Costos de negocio asumidos (S6, S14)
- Dependencia de puntajes de terceros
- Equidad no evaluada: sin atributos protegidos
- Historial en memoria, no en un feature store

Cómo las acota el proyecto

- Ruido excluido con evidencia y controles
- Validación por cuenta y periodos sesgados fuera
- Costos en config.yaml y análisis de sensibilidad
- Sin DISTRUST el PR-AUC solo baja a 0,532
- Faltantes como señal y PSI de cada variable
- Mismo código en entrenamiento y producción

Gracias

Cada decisión de este proyecto tiene un porqué y una prueba: en los datos, en los tests o en el análisis de sensibilidad.

— github.com/alvarojcabrera/deteccion-fraude-identidad · README con todos los comandos